

# Avaliação pela Moda, Média ou Mediana?

Estudo de Caso

*Luiz Fernando Palin Droubi*

*Willian Zonato*

*01/03/2018*

## 1 INTRODUÇÃO

## 2 REVISÃO BIBLIOGRÁFICA

### 2.1 Esperança matemática ou Valor Esperado

Segundo WIKIPEDIA (2018), a “**esperança matemática** de uma variável aleatória é a soma do produto de cada probabilidade de saída da experiência pelo seu respectivo valor. Isto é, representa o valor médio ‘esperado’ de uma experiência se ela for repetida muitas vezes”. Matematicamente, a Esperança de uma variável aleatória  $X$  é representada pelo símbolo  $E[X]$ , de tal forma que, pela definição dada acima, no caso de uma variável aleatória discreta:

$$E[X] = \sum_{i=1}^{\infty} x_i p(x_i)$$

Já para uma variável aleatória contínua, o valor esperado torna-se:

$$E[X] = \int_{-\infty}^{\infty} x f(x) dx$$

Segundo WIKIPEDIA (2018), pode-se demonstrar que, no caso geral:

$$E[g(X)] \neq g(E[X])$$

### 2.2 O problema da retransformação das variáveis

Numa regressão linear logaritmizada, ou seja, uma regressão linear com o logaritmo da variável dependente, para efetuar apropriadamente a retransformação das estimativas de volta a sua escala original, precisa-se ter em conta a desigualdade mencionada na seção 2.1.

Segundo MANNING; MULLAHY (1999), quando ajustamos o logaritmo natural de uma variável  $Y$  contra outra variável  $X$  através da seguinte equação de regressão:

$$\ln(Y) = \beta_0 + \beta_1 X + \epsilon$$

Sabe-se que a melhor estimativa que se pode fazer da variável dependente  $Y$  é o seu Valor Esperado, que neste caso vale:

$$E[Y] = e^{\beta_0 + \beta_1 X} \cdot E[e^{\epsilon}]$$

Embora o valor esperado dos resíduos seja igual a zero, ele está submetido a uma transformação não linear, de maneira que não podemos afirmar que  $E[e^{\epsilon}] = 1$ , como vimos na seção anterior. Desta maneira, o estimador abaixo é enviesado:

$$E[Y] = e^{\beta_0 + \beta_1 X}$$

Se o termo de erro  $\epsilon$  é normalmente distribuído  $N(0, \sigma^2)$ , então um estimador não-enviesado para o valor esperado  $E[Y]$ , de acordo com DUAN (1983), assume a forma vista na equação abaixo DUAN (1983; apud MANNING; MULLAHY, 1999, p. 2 e 6):

$$E[Y] = e^{\beta_0 + \beta_1 X} \cdot e^{\frac{1}{2}\sigma^2}$$

### 3 ESTUDO DE CASO

Neste estudo comparamos a precisão de diversos tipos de modelos estatísticos (regressão linear, regressão não-linear e modelo linear generalizado) sobre dados gerados com erros randômicos normais com média zero e desvio-padrão  $\sigma = 1$ .

#### 3.1 Geração de dados randômicos

Para a geração de dados foi utilizada a seguinte expressão teórica, dentro do intervalo  $0 \leq x \leq 1$ :

$$y = e^{-5x+2}$$

Para obter alguma variabilidade, foram adicionados aos valores teóricos de  $y$  erros normais  $N(0; 0, 2)$ .

```
set.seed(123)
```

```
a = -5
```

```
b = 2
```

```
x = runif(100, 0, 1)
```

```
y = exp(a*x + b + rnorm(100, 0, .2))
```

- Gráfico dos dados gerados

```
plot(x,y, pch = 16, cex = 0.5)
```




Figura 1: Gráfico dos dados gerados

### 3.1.1 Gráfico da variável transformada

```
plot(x, log(y), pch = 16, cex = 0.5)
abline(lm(log(y) ~ x), col = 2)
```




Figura 2: Gráfico da variável transformada

## 3.2 Ajuste da regressão não-linear

```
### NLS Fit
NLfit <- nls(y ~ exp(a*x+b), start = c(a = -10, b = 15))
```

### 3.2.1 Coeficientes

```
co <- coef(NLfit)
co
```

```
##           a           b
## -4.896555212  1.997874467
```

### 3.2.2 Gráfico do modelo não-linear

```
f <- function(x,a,b) {exp(a*x+b)}
curve(f(x = x, a = co[1], b = co[2]), col = 2, lwd = 1.2)
curve(f(x = x, a = -5, b = 2), col = 3, lwd = 1.5, add = TRUE)
```




Figura 3: Gráfico do modelo não-linear

### 3.2.3 Estimativas do modelo não-linear

```
pNLfit <- predict(NLfit, newdata = data.frame(x = .7))
pNLfit
```

```
## [1] 0.2393773308
```

O valor teórico obtido pela equação original ( $y = e^{-5x+2}$ ) é de:

```
Yteorico <- exp(-5*.7 + 2)
round(Yteorico, 4)
```

```
## [1] 0.2231
```

$$\epsilon = \frac{\hat{Y} - Y_{teórico}}{Y_{teórico}}$$

O valor obtido pelo modelo é muito próximo do valor teórico. O erro do modelo, portanto, é de 7.28%.

## 3.3 Ajuste de modelo linear generalizado

### 3.3.1 Poisson

```
Gfit <- glm(y ~ x, family = poisson())
summary(Gfit)
```

```
##
## Call:
## glm(formula = y ~ x, family = poisson())
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -0.78105080 -0.11407910 -0.02334406  0.04517457  0.78120241
##
## Coefficients:
##              Estimate Std. Error  z value Pr(>|z|)
```

```
## (Intercept)  2.0129853  0.1265714  15.90394 < 2.22e-16 ***
## x          -4.9957447  0.4647721 -10.74881 < 2.22e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##      Null deviance: 184.288851  on 99  degrees of freedom
## Residual deviance:   4.991623  on 98  degrees of freedom
## AIC: Inf
##
## Number of Fisher Scoring iterations: 4
```

### 3.3.1.1 Estimativa com o modelo linear generalizado com Poisson

```
pGfit <- predict(Gfit, newdata = data.frame(x = .7), type = "response")
pGfit
```

```
##          1
## 0.2267207901
```

O valor obtido pelo modelo também é muito próximo do valor teórico obtido pela equação original ( $y = e^{-5x+2}$ ). Neste caso, o erro do modelo é de 1.61%.

### 3.3.2 Gauss

```
Gfit2 <- glm(y ~ x, family = gaussian(link = "log"))
summary(Gfit2)
```

```
##
## Call:
## glm(formula = y ~ x, family = gaussian(link = "log"))
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -1.52566206  -0.10270628  -0.01630332   0.02118162   2.06949483
##
## Coefficients:
##      Estimate Std. Error  t value Pr(>|t|)
## (Intercept)  1.9978743  0.0268358  74.44810 < 2.22e-16 ***
## x          -4.8965539  0.1736556 -28.19692 < 2.22e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for gaussian family taken to be 0.1633725569)
##
##      Null deviance: 313.906827  on 99  degrees of freedom
## Residual deviance:  16.010526  on 98  degrees of freedom
## AIC: 106.59533
##
## Number of Fisher Scoring iterations: 4
```

### 3.3.2.1 Estimativa com o modelo linear generalizado com Gauss

```
pGfit2 <- predict(Gfit2, newdata = data.frame(x = .7), type = "response")
pGfit2
```

```
##          1
```

```
## 0.2393775107
```

O valor obtido pelo modelo também é muito próximo do valor teórico obtido pela equação original ( $y = e^{-5x+2}$ ). Neste caso, o erro do modelo é de 7.28%. Observar que a adoção de ajuste por modelo linear generalizado com família gaussiana e *log-link* é equivalente ao ajustamento de um modelo de regressão não-linear, como visto na seção anterior.

### 3.4 Ajuste de Regressão Linear com variável dependente transformada

```
### LM Fit
fit <- lm(log(y) ~ x)
s <- summary(fit)
s

##
## Call:
## lm(formula = log(y) ~ x)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.44759471 -0.12264594 -0.00394687  0.11926677  0.44344532
##
## Coefficients:
##              Estimate Std. Error  t value Pr(>|t|)
## (Intercept)  1.99820803  0.03921100  50.96040 < 2.22e-16 ***
## x           -5.01796627  0.06836424 -73.40045 < 2.22e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1938582 on 98 degrees of freedom
## Multiple R-squared:  0.9821351, Adjusted R-squared:  0.9819528
## F-statistic: 5387.626 on 1 and 98 DF, p-value: < 2.2204e-16
```

#### 3.4.1 Gráfico do modelo linear

```
#plotmod(fit)
```

#### 3.4.2 Estimativas

a. Pela mediana

```
Y <- predict(fit, newdata = data.frame(x = .7))
p_mediana <- exp(Y)
p_mediana
```

```
##      1
## 0.2199470683
```

O erro do modelo, neste caso, é de -1.43%.

b. Pela moda

```
p_moda <- exp(Y - s$sigma^2)
p_moda
```

```
##      1
## 0.2118346261
```

O erro do modelo, neste caso, é de -5.06%.

c. Pela média

```
p_media <- exp(Y + s$sigma^2/2)
p_media
```

```
##          1
## 0.2241190594
```

O erro do modelo, neste caso, é de 0.443%.

### 3.5 Comparação dos resultados obtidos

Modelo	Previsão	Erro (%)
<b>Valor Teórico</b>	<b>0.2231</b>	—
Regressão Não-Linear	0.2394	7.28%
GLM (Poisson)	0.2267	1.61%
GLM (Gauss)	0.2394	7.28%
LM (Mediana)	0.2199	-1.43%
LM (Moda)	0.2118	-5.06%
LM (Média)	0.2241	0.443%

## 4 Método de Monte-Carlo

O resultados acima não devem ser interpretados como taxativos, pois os valores encontrados foram obtidos de dados gerados randômicamente.

Para uma comparação mais precisa entre os modelos testados, utilizamos o método de Monte Carlo, simulando os dados randomicamente a cada iteração. Finalmente, comparamos o valor médio obtido por cada cada modelo ao valor teórico.

```
Nsim <- 500
pNL <- vector(mode = "numeric", length = Nsim)
pG <- vector(mode = "numeric", length = Nsim)
pG2 <- vector(mode = "numeric", length = Nsim)
p_mediana <- vector(mode = "numeric", length = Nsim)
p_moda <- vector(mode = "numeric", length = Nsim)
p_media <- vector(mode = "numeric", length = Nsim)
for (i in 1:Nsim) {
  y = exp(a*x + b + rnorm(100, 0, .2))
  NLfit <- nls(y ~ exp(a*x+b), start = c(a = -10, b = 15))
  Gfit <- glm(y ~ x, family = poisson())
  Gfit2 <- glm(y ~ x, family = gaussian(link = "log"))
  fit <- lm(log(y) ~ x)
  s <- summary(fit)
  pNL[i] <- predict(NLfit, newdata = data.frame(x = .7))
  pG[i] <- predict(Gfit, newdata = data.frame(x = .7), type = "response")
  pG2[i] <- predict(Gfit2, newdata = data.frame(x = .7), type = "response")
  p_mediana[i] <- exp(predict(fit, newdata = data.frame(x = .7)))
  p_moda[i] <- exp(predict(fit, newdata = data.frame(x = .7)) - s$sigma^2)
  p_media[i] <- exp(predict(fit, newdata = data.frame(x = .7)) + s$sigma^2/2)
}
```

- Gráficos

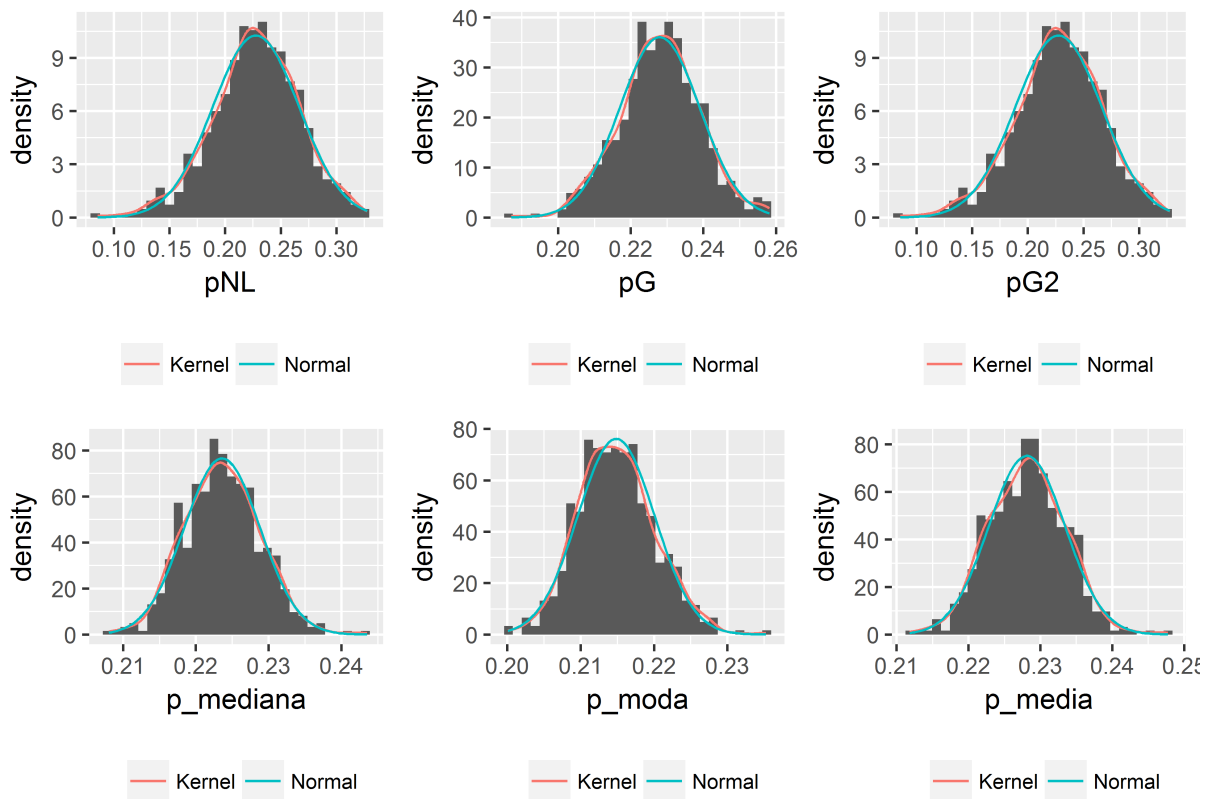


Figura 4: Histogramas das variáveis simuladas

Modelo	Previsão	$\sigma^2$	Erro
<b>Valor Teórico</b>	<b>0.2231</b>	—	—
Regressão Não-Linear	0.2275	0.0389	1.96%
GLM (Poisson)	0.2279	0.0111	2.16%
GLM (Gauss)	0.2275	0.0389	1.96%
LM (Mediana)	0.2236	0.0052	0.207%
LM (Moda)	0.2148	0.0052	-3.72%
LM (Média)	0.2281	0.0053	2.23%

## REFERÊNCIAS

DUAN, N. Smearing estimate: A nonparametric retransformation method. **Journal of the American Statistical Association**, v. 78, n. 383, p. 605–610, 1983. Taylor & Francis. Disponível em: <<http://www.tandfonline.com/doi/abs/10.1080/01621459.1983.10478017>>..

MANNING, W. G.; MULLAHY, J. **Estimating log models: To transform or not to transform?** Working Paper, National Bureau of Economic Research, 1999.

WIKIPEDIA. Valor esperado — Wikipedia, the free encyclopedia., 2018. Disponível em: <[https://pt.wikipedia.org/wiki/Valor\\_esperado](https://pt.wikipedia.org/wiki/Valor_esperado)>..